

Contents

MARL + LLM 研究发展综述	1
摘要	2
1. 研究范围、检索方法与证据说明	2
1.1 三个研究问题	2
1.2 检索与归档流程	3
1.3 证据分层	3
2. 领域全景：两条主线与一个汇聚层	4
2.1 范式 A：基于 LLM 的多智能体系统	4
2.2 范式 B：利用 LLM 辅助 MARL	4
2.3 汇聚层：多智能体 LLM 的强化学习	5
2.4 先看例子：LLM 到底扮演什么角色	5
3. 发展历程：从两条根到一个汇聚层	5
3.1 2017-2021：两条根分别成熟	5
3.2 2022-2023：范式爆发	6
3.3 2024：体系化与评测化	6
3.4 2025-2026：在 RL 处汇聚	7
4. 方向 A：基于 LLM 的多智能体系统	7
4.1 架构、角色与软件工程	7
4.2 协作、辩论与反思	7
4.3 拓扑、工作流与动态编排	8
4.4 社会模拟与垂直应用	8
4.5 评测、失败模式与可靠性	8
5. 方向 B：利用 LLM 辅助 MARL	9
5.1 分层规划、技能选择与具身控制	9
5.2 奖励设计、奖励塑造与稳定性	9
5.3 信用分配：从反事实基线到 LLM critic	9
5.4 策略协同、联合训练与样本效率	10
6. 2025-2026 最新进展	10
6.1 最新方向对照表	10
6.2 最新趋势的五句话	10
7. 实验方法地图	11
7.1 环境与任务选择	11
7.2 训练与推理协议	11
7.3 指标与基线	12
7.4 一个可复用的实验模板	12
8. 关键人物、团队与代表工作	13
9. 研究机会与可执行路线	14
9.1 机会一：验证 credit 的因果正确性	14
9.2 机会二：研究奖励平稳性与 replay 污染	14
9.3 机会三：动态拓扑与通信成本	15
9.4 机会四：三 agent、部分观测与异构模型	15
9.5 机会五：统一预算感知评测	15
9.6 一个 12 周研究路线	15
10. 结论	16
附录 A：本地文件结构	16
附录 B：关键节点节选	16
附录 C：如何使用这份材料	17
附录 D：边界与后续补全	17

MARL + LLM 研究发展综述

副标题：从基于 LLM 的多智能体系统，到利用 LLM 辅助多智能体强化学习

摘要

MARL + LLM 不是一个单点方法，而是一条由两条独立研究传统汇合而成的研究带。

第一条主线是 **基于 LLM 的多智能体系统 (LLM-based Multi-Agent Systems, LaMAS)**。它把 LLM 本身当作智能体，通过角色分工、对话协议、工具调用、记忆、反思、辩论和动态拓扑，组织多个语言模型共同完成任务。这条线的核心问题是：多个 LLM 如何组织、如何通信、如何分工、如何评测，以及为什么会在看似合理的协作流程中失败。

第二条主线是 **利用 LLM 辅助 MARL (LLM-assisted MARL)**。它不要求 LLM 直接成为低层控制器，而是让 LLM 处在高层规划、技能选择、奖励函数设计、信用分配或策略协同的位置，由传统 MARL 继续学习低层执行策略。这条线的核心问题是：语言模型能否把人类知识、任务语义和环境约束转成更好的学习信号，从而降低奖励工程、样本效率和信用分配的难度。

2025-2026 年，两条线在 **多智能体 LLM 的强化学习 (RL for multi-agent LLM systems)** 处明显汇聚。代表工作包括 MAPoRL、GiGPO、MARFT、SRPO、TRACER、MASkills 等：它们不再只优化提示词或工作流，而是直接优化多智能体轨迹、回合级信用、角色分工和集合策略。与此同时，LLM-MCA 与 ReMAC 分别从信用分配和双层奖励设计两个方向，把 LLM 变成传统 MARL 的训练信号生成器。

本综述的核心判断是：

1. 领域的发展方向是从“组织多个 LLM”走向“训练多个 LLM”，再走向“用 LLM 改善 MARL 的学习信号”。
2. 两条主线共同面对同一个瓶颈：团队层面的最终回报，无法直接说明每个智能体、每个回合或每项技能贡献了什么。
3. 下一阶段最有价值的研究，不是继续增加 agent 数量，而是建立可反事实验证、预算可比、跨环境可复现的信用与奖励评价标准。
4. 实验设计应从可枚举小环境出发，先验证信号正确性，再迁移到具身协作、工具使用和长程任务。




Figure 1: MARL + LLM 文献增长与本地全文覆盖


1. 研究范围、检索方法与证据说明

1.1 三个研究问题

本综述围绕三个问题组织：

- **RQ1**：LaMAS 与 LLM-assisted MARL 两条主线分别如何形成、分化和相互影响？
- **RQ2**：哪些团队、时间节点和代表工作推动了领域发展？每条分支的核心方法是什么？
- **RQ3**：2025-2026 年最新进展集中在哪些方向？当前主流实验方法、基准、指标和可复现边界是什么？

MARL + LLM 研究发展树



1.2 检索与归档流程


本项目的本地文献库由四层组成：

层级	内容	当前结果
检索候选	OpenAlex、arXiv、Crossref 多关键词检索与去重	177 条
开放全文	通过 arXiv、Unpaywall、OpenAlex、OpenReview、ACL Anthology、出版社 PDF 链接下载并校验	150 篇
核心文献	经典根节点、两条主线、评测、综述和 2024-2026 前沿	130 条
关键节点	用于发展树和时间线的人工核实里程碑	75 个

本地归档包含：

- papers/：PDF 原文，共 150 篇通过 PDF 文件头和页数校验；
- text/：逐页抽取的文本，共 150 篇；
- data/corpus.json、data/corpus.csv：完整元数据、分支、DOI/arXiv、下载状态和哈希；
- data/curated_corpus.json、data/curated_bibliography.csv：综述核心文献；
- data/milestones.csv：75 个关键节点的时间、作者、机构/团队信息、代表工作和一句话贡献；
- data/references.bib：可用于后续论文写作的 BibTeX；
- figures/：时间线、研究树、范式对比、方法-基准矩阵、实验流程和证据覆盖图。

图表质检采用“数据图 + 技术信息图”双轨：时间线、方法矩阵和证据覆盖属于科研数据图，使用 matplotlib 并经过 300 DPI 与布局自检；研究树和实验流程使用 faro 技术图版本，SVG 精确源文件保留在 figures/，用于逐字校对和后续编辑。



- **元数据证据**：只有标题、作者、DOI/arXiv 和摘要，用于确认领域存在和趋势，不用于推断实验结论；
- **人工核实节点**：对经典论文的年份、作者和代表工作做人工校正，避免 Crossref 重印记录或会议镜像造成年份漂移。

因此，本报告中的“最新趋势”以 2025-2026 年全文或可核实摘要为基础；对尚未形成稳定共识的方向，会明确写成“开放问题”或“待验证假设”。

2. 领域全景：两条主线与一个汇聚层




Figure 4: 两条主线与一个汇聚层

2.1 范式 A：基于 LLM 的多智能体系统

LaMAS 把 LLM 作为智能体本体。一个典型系统包含：

- **角色层**：每个 LLM 被赋予角色、目标和权限；
- **通信层**：智能体通过自然语言、结构化消息或共享黑板交换信息；
- **记忆层**：保存历史轨迹、经验、反思和技能；
- **工具层**：调用搜索、代码执行、浏览器、数据库或机器人 API；
- **编排层**：决定谁在什么时候说话、调用什么工具、是否继续、是否重规划；
- **评测层**：测量任务成功率、通信成本、协作行为和失败模式。

LaMAS 的早期代表是 CAMEL、AutoGen、MetaGPT 和 ChatDev。它们把“多智能体”从提示词拼接推进到可编程的对话协议和角色流水线。随后，AgentVerse、多智能体辩论、ChatEval 和 Reflexion 把协作扩展到辩论、反思和评估。2024 年以后，GPTSwarm、DyLAN、MACNET、Optima 和 Evolving Orchestration 进一步把组织结构和通信拓扑当作可优化对象。

2.2 范式 B：利用 LLM 辅助 MARL

LLM-assisted MARL 不要求 LLM 承担全部决策。LLM 主要出现在四个位置：

LLM 位置	代表工作	解决的问题
高层规划器	SayCan、Inner Monologue、ProgPrompt、Voyager、RoCo、L2M2	把长程任务分解为技能或子目标
奖励设计器	Eureka、Text2Reward、Reward Design with LMs、ReMAC、LLM-ALSO	降低奖励工程成本，生成稠密或分层奖励
信用分配器	LLM-MCA、GiGPO、MASkills、TRACER	把团队回报转成 agent、回合或技能级信号
策略协同器	LAMARL、LLM-Mediated Guidance、MAPoRL、MARFT	生成先验策略、引导训练或直接优化协作策略

这条线的共同假设是：LLM 拥有任务语义、常识和代码生成能力，可以把这些能力转成 MARL 难以从零学到的结构先验。

2.3 汇聚层：多智能体 LLM 的强化学习

当 LaMAS 开始用强化学习优化参数，当 LLM-assisted MARL 开始把 LLM 策略纳入联合训练，两条线就进入同一个问题空间：

如何从多智能体轨迹中构造可训练、可解释、可验证的个体或集合信号？

这一问题把传统 MARL 的信用分配、价值分解、反事实基线和策略优化，与 LLM 的语义推理、工具反馈和自然语言解释连接起来。2025-2026 年的 MAPoRL、GiGPO、MARFT、SRPO、TRACER 和 MASkills 正是这一汇聚层的代表。

2.4 先看例子：LLM 到底扮演什么角色

“LLM + MARL”并不表示 LLM 永远做同一件事。判断一篇论文时，先问五个问题：LLM 的输出是什么？谁消费这个输出？LLM 参数是否更新？LLM 调用频率是多少？最终执行任务的是谁？

论文/方法	LLM 的角色	谁最终执行	谁被训练
CAMEL / AutoGen	角色对话执行者、工具调用者	LLM + 工具	通常不训练参数
MetaGPT / ChatDev	角色化软件工程师	LLM 流水线	通常不训练参数
Multiagent Debate	辩手 + 批评者	LLM 群体	通常不训练参数
Reflexion	执行者 + 反思器	LLM	通常不训练参数
SayCan / Voyager / L2M2	高层规划器、技能选择器	技能库 / 低层策略	低层技能或策略
Eureka / Text2Reward / ReMAC	奖励函数程序员	RL / MARL 策略	RL / MARL 策略
LLM-MCA	集中式 critic、信用分配器	低层 MARL 策略	低层 MARL 策略
LAMARL	先验策略 + 奖励生成器	MARL 策略	MARL 策略
MARFT / MAPoRL / GiGPO	被 RL 训练的多智能体策略	LLM agents	LLM 参数或部分参数

最短记忆法是：**LLM 是嘴、是脑、是教练、是调度员，也可能是被训练的学生**。详细解释和 12 个逐条例子见 LLM 角色说明.md。

3. 发展历程：从两条根到一个汇聚层

3.1 2017-2021：两条根分别成熟

MARL 根节点关注的是多智能体联合决策的优化困难：

- MADDPG (Lowe et al., 2017) 把 CTDE 推向连续动作和混合合作-竞争环境；
- VDN (Sunehag et al., 2017) 和 QMIX (Rashid et al., 2018) 用价值分解解决团队回报到个体效用的映射；
- COMA (Foerster et al., 2018) 用反事实基线处理信用分配；
- SMAC (Samvelyan et al., 2019) 提供标准化合作 MARL 环境；



Figure 5: MARL + LLM 研究发展时间线

- MAPPO (Yu et al., 2021) 证明 PPO 在合作 MARL 中是非常强的基线；
- ROMA (Wang et al., 2020) 和 LIIR (Yang et al., 2020) 分别从角色分化和学习信号设计两个方向扩展 MARL。

LLM 根节点关注的是通用推理和行动能力：

- Transformer (Vaswani et al., 2017) 提供统一序列建模底座；
- GPT-3 (Brown et al., 2020) 展示少样本上下文学习；
- InstructGPT (Ouyang et al., 2022) 建立 RLHF 到通用指令模型的路线；
- CoT (Wei et al., 2022) 把推理过程变成可提示、可优化的对象；
- ReAct (Yao et al., 2022) 把推理与工具行动交替组合。

这两条根在 2022 年以前基本独立：MARL 研究的是低层策略学习，LLM 研究的是语言推理和工具使用。

3.2 2022-2023：范式爆发

2022-2023 年是领域从“语言模型能做什么”转向“多个语言模型如何协作”的关键窗口。

规划与具身控制方面：

- SayCan (Ahn et al., 2022) 把语言计划限制在可执行技能上；
- Inner Monologue (Huang et al., 2022) 把语言反馈带入闭环控制；
- Language Models as Zero-Shot Planners (Huang et al., 2022) 证明 LLM 可以作为零样本任务分解器；
- Code as Policies (Liang et al., 2023) 和 ProgPrompt (Singh et al., 2023) 把自然语言转成可执行策略代码；
- Voyager (Wang et al., 2023) 把开放世界技能库与持续学习结合。

多智能体系统方面：

- Reflexion (Shinn et al., 2023) 用自然语言反思实现无梯度自我改进；
- Generative Agents (Park et al., 2023) 把多智能体推进到社会模拟；
- CAMEL (Li et al., 2023)、AutoGen (Wu et al., 2023) 和 MetaGPT (Hong et al., 2023) 建立角色对话、可编程编排和 SOP 流水线；
- AgentVerse (Chen et al., 2023) 引入动态成员调整；
- Multiagent Debate (Du et al., 2023) 和 ChatEval (Chan et al., 2023) 用分歧提升事实性和评估质量。

LLM 辅助 MARL 方面：

- Eureka (Ma et al., 2023) 让 LLM 生成并迭代奖励代码；
- Text2Reward (Xie et al., 2023) 把自然语言任务描述转成奖励函数；
- Reward Design with Language Models (Kwon et al., 2023) 直接让语言模型参与奖励设计；
- RLAIIF (Lee et al., 2023) 把 AI 反馈扩展为可规模化的训练信号；
- RoCo (Mandi et al., 2023) 让多机器人通过语言辩证进行协作与重规划。

3.3 2024：体系化与评测化

2024 年的关键词是“体系化”：

- LaMAS 综述 (Guo et al., 2024) 建立智能体、通信、能力和评测的分类框架;
- AgentBench、WebArena、GAIA、SWE-bench、 τ -bench、OSWorld 和 AgentGym 把评测从单一问答扩展到工具、Web、软件和真实计算机环境;
- GPTSwarm (Zhuge et al., 2024) 把智能体组织建模为可优化图;
- DyLAN (Liu et al., 2023/2024) 在推理时动态选择智能体网络;
- MACNET (Qian et al., 2024) 把多智能体协作扩展到更大团队;
- Optima (Chen et al., 2024/2025) 用生成-排序-选择-训练提升通信效率;
- ProAgent (Zhang et al., 2024) 和 Hypothetical Minds (Cross et al., 2024) 把角色理解、伙伴建模和心理理论引入多智能体协作;
- Multi-Agent RL from Human Feedback (Ganapathi et al., 2024) 开始系统研究多智能体偏好反馈的数据覆盖与算法。

3.4 2025-2026: 在 RL 处汇聚

2025-2026 年的新工作表现出五个明确趋势。

趋势一：从提示词优化走向参数优化。 MAPoRL 用多智能体后协同训练优化协作生成; RAGEN、AgentGym-RL 研究多轮交互 RL; MARFT 把 LaMAS 建模为 Flex-MG，用多智能体优势分解微调异构智能体。

趋势二：从最终回报走向细粒度信用。 LLM-MCA 用集中式 LLM critic 生成 per-agent credit; GiGPO 用组内组外结构做多轮信用分配; TRACER 用 turn-level regret matching 和内部信用处理稀疏奖励与搭便车; MASKills 用技能条件信用和层次聚合支持持续优化。

趋势三：从固定拓扑走向动态组织。 GPTSwarm、DyLAN、MACNET、Optima、Evolving Orchestration、MoRSE 和 2026 年的 E2-Explainer 都在学习或解释通信拓扑与角色分工。

趋势四：从单一任务指标走向预算、可靠性和安全。 MAST 把多智能体失败拆成规格、组织和验证三类机制; ToMAS 把失败轨迹转成可评测的心理理论项目; 2026 年的 unsafe-action propagation 工作研究多机器人 LLM 协作中的安全风险传播。

趋势五：从单智能体 RL 走向集合、群体和角色分解训练。 SRPO 把团队动作当作集合做相对策略优化; Divide and Cooperate 把搜索与生成解耦; MARFT 用顺序优势分解处理异构智能体; LLM-ALSO 和 Regime-Conditional Stabilisation 则把奖励设计从一次性生成推进到训练动态和稳定性问题。

4. 方向 A: 基于 LLM 的多智能体系统

4.1 架构、角色与软件工程

LaMAS 的第一代架构把多智能体系统实现为“角色 + 对话 + 工具”的组合。

工作	时间	核心机制	对领域的贡献
CAMEL	2023	角色扮演与对话协议	最小可运行的 LLM 社会协作骨架
AutoGen	2023	可编程对话与工具调用	把多智能体编排工程化
MetaGPT	2023	SOP 与角色流水线	把软件工程流程嵌入多智能体协作
ChatDev	2023	多角色软件开发工作流	端到端软件生成案例
AgentVerse	2023	动态成员调整	从静态角色走向动态组织
MACNET	2024	规模化协作网络	探索更大团队和更复杂拓扑
MoRSE	2026	role-subtask 专家混合	从提示词分工走向参数级专业化

这一分支的演进逻辑很清楚：从“让多个 LLM 对话”，到“让多个 LLM 按照流程协作”，再到“让组织结构和角色分工本身可优化”。

4.2 协作、辩论与反思

辩论和反思是 LaMAS 最早成熟的协作机制。

- **Multiagent Debate** (Du et al., 2023): 多个模型提出答案并相互批评，最终答案通过多轮辩论收敛；
- **ChatEval** (Chan et al., 2023): 把多智能体辩论用于文本评估；
- **Reflexion** (Shinn et al., 2023): 用语言反思替代梯度更新，形成经验记忆；
- **AgentVerse** (Chen et al., 2023): 把成员调整和协作评估纳入系统循环；
- **SOTOPIA** (Zhou et al., 2023): 用社会互动场景评测语言智能体的社交能力。

这些工作的共同经验是：**多智能体的价值不只来自并行计算，而来自角色差异、信息不对称和可验证的分歧**。如果所有 agent 共享同一上下文、同一目标和同一模型，协作收益会迅速下降。

4.3 拓扑、工作流与动态编排

2024 年以后，研究重点从“有哪些 agent”转向“agent 之间如何连接”。

- **GPTSwarm** (Zhuge et al., 2024): 把 agent 组织表示为可优化图，用图优化搜索协作结构；
- **DyLAN** (Liu et al., 2023/2024): 在推理时动态选择参与者和通信边；
- **MACNET** (Qian et al., 2024): 用大规模协作网络扩展 agent 数量；
- **Optima** (Chen et al., 2024/2025): 通过生成、排序、选择、训练优化通信效率和任务效果；
- **Evolving Orchestration** (Dang et al., 2025): 用 puppeteer 式中心编排器动态调度 agent；
- **E2-Explainer** (2026): 用因果推断解释通信拓扑，识别关键子图；
- **AgentNet** (2026): 每个 agent 同时携带 router 和 executor，通过局部 peer-to-peer 决策完成任务分配。

这条分支的核心问题从“通信是否发生”变成了“通信是否值得”。在 token 成本和延迟成为硬约束后，固定全连接对话很快失去优势，动态拓扑、稀疏通信和角色路由成为更自然的设计。

4.4 社会模拟与垂直应用

- **Generative Agents** (Park et al., 2023): 在 Smallville 环境中模拟居民日常行为，展示记忆、反思和计划的社会模拟能力；
- **AgentSociety** (Piao et al., 2025): 把生成式智能体推进到大规模社会科学模拟；
- **ChatDev**、**MapCoder**、**Agent Laboratory**: 把 LaMAS 应用于软件开发、代码生成和科研辅助；
- **Deep Research in Physical Sciences / PhySciBench** (2026): 用 200 道专家题评测多智能体深度研究能力。

应用分支的共同挑战是评测：软件开发有测试用例，物理研究有专家题，但社会模拟和科研协作往往缺少可自动验证的目标。

4.5 评测、失败模式与可靠性

LaMAS 的评测经历了从“任务成功率”到“协作过程”和“失败机制”的扩展。

评测类型	代表工作	主要测量
通用工具与推理	AgentBench、GAIA	多环境任务完成率
Web 与计算机操作	WebArena、OSWorld	网页/桌面长程操作
软件工程	SWE-bench	真实 GitHub issue 修复
工具-用户交互	τ -bench	真实业务约束下的交互
多智能体协作/竞争	MultiAgentBench	协作、竞争与通信
社会互动	SOTOPIA	社交目标与关系行为
失败机制	MAST、ToMAS	规格、组织、验证和心理理论失败

MAST (Cemri et al., 2025) 把多智能体失败归为三类：规格与系统设计失败、智能体间组织与协调失败、任务验证与终止失败。ToMAS (2026) 进一步把 MAST 中的失败轨迹转成可评测的心理理论项目，并用 GRPO 做小规模可行性实验。

这组工作给出一个非常重要的结论：**多智能体系统的失败往往不是单个模型能力不足，而是组织、通信和验证机制的设计失败**。因此，评测必须记录过程，而不仅是最终答案。

5. 方向 B: 利用 LLM 辅助 MARL

5.1 分层规划、技能选择与具身控制

LLM 辅助 MARL 最早成熟的路径是分层规划：LLM 负责高层任务分解，低层策略负责连续控制。

工作	时间	LLM 的位置	低层执行
SayCan	2022	语言计划 + 可行性打分	机器人技能库
Inner Monologue	2022	闭环语言反馈	机器人原语
Zero-Shot Planners	2022	零样本任务分解	行为原语
ProgPrompt	2023	程序化提示	机器人动作
Code as Policies	2023	生成策略代码	控制 API
Voyager	2023	开放世界技能库	Minecraft 动作
SayPlan	2023	3D 场景图 + 任务规划	机器人导航
RoCo	2023	多机器人语言辩证	运动规划器
ProAgent	2024	角色理解与主动协作	多智能体策略
L2M2	2025	LLM 高层规划	MARL 低层执行
Hierarchical Control in Multi-Agent Games	2026	LLM 选择技能	RL 反应式执行
Bayesian Partner Modelling	2026	层级规划 + 贝叶斯伙伴跟踪	自适应重规划

这条分支的核心经验是：LLM 的规划能力只有在“可执行性约束”下才会转化为真实收益。SayCan 用 affordance 打分，Inner Monologue 用环境反馈，Voyager 用技能库，L2M2 用 MARL 低层策略，都是在把语言计划锚定到可执行动作空间。

5.2 奖励设计、奖励塑造与稳定性

奖励设计是 LLM-assisted MARL 最活跃的分支。

- **Eureka (Ma et al., 2023)**：LLM 生成奖励代码，根据训练反馈迭代；
- **Text2Reward (Xie et al., 2023)**：自然语言任务描述直接转成奖励函数；
- **Reward Design with Language Models (Kwon et al., 2023)**：用语言模型选择或生成奖励；
- **RLAIF (Lee et al., 2023)**：用 AI 反馈替代部分人类反馈；
- **ReMAC (Li et al., 2025)**：同时生成 agent-level 与 team-level 奖励，维护 reward-policy population，并通过训练反馈反思；
- **LLM-ALSO (2026)**：把奖励/学习信号优化变成迭代过程，面向 MARL 训练动态；
- **Regime-Conditional Stabilisation (2026)**：指出动态更新 LLM 奖励权重会破坏 potential-based reward shaping 的平稳性，并污染 replay buffer。

这一分支的核心矛盾是：

LLM 能生成语义丰富的奖励，但奖励一旦进入 off-policy MARL，就必须满足平稳性、尺度和可验证性要求。

ReMAC 的价值在于把奖励分成个体技能和团队协调两个层次，并用 population 搜索降低单次生成的不稳定性。2026 年的 Regime-Conditional 工作则进一步说明：奖励生成不是一次性代码生成问题，而是训练动态问题。

5.3 信用分配：从反事实基线到 LLM critic

信用分配是 MARL 的经典难题，也是 LLM 辅助 MARL 最自然的切入点。

- **COMA (Foerster et al., 2018)**：用反事实基线估计每个 agent 的边际贡献；
- **LIIR (Yang et al., 2020)**：把内在奖励/学习信号作为可学习对象；
- **LLM-MCA (Nagpal et al., 2025)**：集中式 LLM critic 读取联合轨迹，输出 per-agent credit 和自然语言解释；LLM-TACA 进一步在训练期提供任务分配；
- **GiGPO (Feng et al., 2025)**：用组内组外结构为多轮 LLM agent 提供细粒度信用；
- **TRACER (2026)**：用 turn-level regret matching 和 inner reinforcement credit 处理多轮协作的稀疏奖励、角色搭便车和协议震荡；
- **MASKills (2026)**：以技能为单位做持续优化，使用 skill-conditioned credit 和层次信用聚合；

- **Divide and Cooperate (2026)**: 把搜索和生成角色解耦，用跨智能体学习信号缓解角色间信用冲突；
- **ToMAS (2026)**: 把失败轨迹转成心理理论题，并用二元奖励做 GRPO 可行性实验。

这条分支的演化可以写成：

- 团队标量回报
- > 价值分解 / 反事实基线
 - > 可解释的 LLM critic
 - > agent-level / turn-level / skill-level credit
 - > 角色分解与跨智能体训练信号

但最关键的验证问题仍然存在：**LLM 给出的 credit 是否接近真实反事实贡献**？当前多数工作只验证最终任务分数，没有直接测量 credit 的因果正确性。这是下一阶段最值得投入的实验方向。

5.4 策略协同、联合训练与样本效率

当 LLM 不只生成信号，而是参与策略更新时，就进入多智能体 LLM 的 RL。

- **MAPoRL (Park et al., 2025)**: 多智能体后协同训练，把协作生成和强化学习统一；
- **MARFT (Anonymous, 2026 under review)**: 用 Flex-MG 表示异构、异步、动态组织的 LaMAS，用多智能体优势分解顺序优化 agent；
- **RAGEN (Wang et al., 2025)**: 研究多轮交互 RL 中的自演化和稳定训练；
- **AgentGym-RL (Xi et al., 2025)**: 面向长程决策的多轮强化学习训练框架；
- **SRPO (2026)**: 把团队动作当作集合，构造 setwise relative advantage，并做集合级裁剪；
- **LAMARL (Zhu et al., 2025)**: LLM 同时生成先验策略和奖励函数，提升 MARL 样本效率；
- **LLM-Mediated Guidance (Siedler & Gemp, 2025)**: 用自然语言或规则控制器引导 MARL 学习轨迹。

这条分支的共同目标是降低探索成本：LLM 提供先验、任务结构或高层动作，MARL 负责低层优化；或者反过来，用 RL 优化多个 LLM 的协作策略。

6. 2025-2026 最新进展

6.1 最新方向对照表

方向	代表工作	核心创新	仍需验证
多智能体后协同训练	MAPoRL	协作生成 + RL 联合训练	跨模型、跨任务的稳定性
顺序优势分解	MARFT	Flex-MG + agent 级优势分解	动态 DAG 与外部基线
组内组外信用	GiGPO	critic-free、多轮细粒度 credit	credit 因果正确性
集合策略优化	SRPO	setwise relative advantage	集合规模扩展与方差
回合级信用	TRACER	regret matching + inner credit	多轮任务的泛化
技能持续优化	MASkills	技能库、层次信用、动量平滑	技能冲突与长期记忆
双层奖励设计	ReMAC	agent-level + team-level reward population	三 agent、部分观测、代码发
LLM critic	LLM-MCA	per-agent credit + 自然语言解释	counterfactual validation
训练动态稳定性	Regime-Conditional	PBRS 平稳性与 replay 污染分析	更大规模与不同 shaping
失败驱动评测	MAST、ToMAS	失败分类与心理理论题	跨框架、跨模型可迁移性
安全传播	Unsafe Actions Propagation	单机器人妥协沿通信链传播	防御与可验证安全约束

6.2 最新趋势的五句话

1. **优化粒度正在变细**：从团队回报到 agent-level、turn-level、skill-level credit。
2. **优化对象正在变广**：从策略参数扩展到角色、拓扑、技能库、奖励函数和协作协议。
3. **训练方式正在合流**：提示词、SFT、DPO、GRPO、PPO、MARL backbone 开始出现在同一个系统里。
4. **评价标准正在扩展**：任务分数之外，成本、延迟、可解释性、稳定性和安全性进入主表。
5. **研究重心正在从“能否协作”转向“协作是否可信、可验证、可预算”**。

7. 实验方法地图

7.1 环境与任务选择

任务类型	常用环境/基准	适合验证什么
可枚举小环境	Matrix Game、Spaceworld、LBF、RWARE	credit 正确性、反事实贡献
合作 MARL	SMAC、ManiCraft、Multi-Agent MuJoCo	样本效率、协作策略、奖励塑造
具身与机器人	ALFRED、RoboSuite、RoCo 任务	高层规划到低层执行
推理与代码	MATH、CMATH、GSM8K、CodeForces、SWE-bench	多智能体推理与代码协作
工具与 Web	WebArena、 τ -bench、OSWorld、GAIA	长程工具使用与真实操作
社会与长程	SOTOPIA、AgentSociety、PhySciBench	社会互动、长程研究、专家评测

选择环境时应遵循“先小后大”：

1. 用可枚举小环境验证 LLM 生成的 credit/reward 是否接近真实贡献；
2. 用合作 MARL 环境验证策略改进和样本效率；
3. 用具身、工具或社会任务验证迁移和长程能力；
4. 最后才增加 agent 数、部分观测和异构模型。




Figure 6: 方法家族 × 评测场景

7.2 训练与推理协议

当前常见协议有六类：

协议	代表工作	特点
Prompt-only SFT	CAMEL、AutoGen、Debate ChatDev、MetaGPT	不改参数，部署快，难以长期优化 可学习角色行为，依赖高质量轨迹
DPO / preference	Optima、部分 LaMAS 优化	训练稳定，依赖偏好数据
PPO / GRPO / group RL	RAGEN、GiGPO、ToMAS	适合多轮交互和可验证奖励
MARL backbone	QMIX、MAPPO、MASAC	低层策略学习，CTDE 或端到端
LLM-as-signal	LLM-MCA、ReMAC、LLM-ALSO	LLM 生成 credit/reward/规划，RL 继续学习

实验设计中最容易混淆的是“LLM 的位置”和“RL 的位置”。建议在论文中明确回答：

- LLM 是策略、critic、planner、reward designer，还是 router？
- LLM 是否更新参数？如果更新，更新哪些参数？
- RL 更新的是低层策略、LLM 策略，还是两者联合？
- LLM 调用发生在每一步、每回合、每个 episode，还是每个 evolution interval？
- 推理成本、token 成本和 wall-clock 是否进入主结果？

7.3 指标与基线

建议至少报告以下指标：

任务指标： - task success rate; - episodic return; - sample efficiency; - zero-shot / few-shot transfer.

信号指标： - credit ranking accuracy; - leave-one-out contribution correlation; - counterfactual return; - reward hacking rate; - component ablation.

协作指标： - single-agent equivalent performance; - agent-removal degradation; - communication volume; - role specialization; - failure recovery rate.

成本与可靠性： - input/output tokens; - LLM calls per episode; - GPU-hour / CPU-hour; - wall-clock latency; - variance across seeds; - safety violation rate.

基线设置： - 无 LLM 的 MARL 基线; - 随机 credit / 错误 reward; - 人工设计 reward; - 固定拓扑 vs 动态拓扑; - 一次性 LLM 信号 vs 迭代 LLM 信号; - 单 agent vs 多 agent 等效比较.

7.4 一个可复用的实验模板

从语言信号到可验证 MARL 改进的实验流程

先固定环境、骨干和预算，再单独改变 LLM 介入位置；最终同时报告任务收益、信号正确性与成本。



Figure 7: 从语言信号到可验证 MARL 改进的实验流程

阶段 1：可枚举信号验证

- 环境：Matrix Game / Spaceworld / LBF
- 方法：人工 reward、LLM reward、LLM credit、随机 credit

- 指标: counterfactual correlation、ranking accuracy、hacking rate

阶段 2: 合作 MARL 策略验证

- 环境: SMAC / ManiCraft / RWARE
- 骨干: QMIX / MAPPO / MASAC
- 变量: LLM 介入位置、调用频率、是否迭代
- 指标: return、sample efficiency、agent-removal degradation

阶段 3: 多智能体 LLM 训练

- 环境: MATH / CodeForces / SWE-bench / WebArena
- 方法: SFT、DPO、GRPO、MAPoRL、MARFT、SRPO
- 指标: task success、token cost、turn-level credit、stability

阶段 4: 可靠性与安全

- 环境: 长程工具、多机器人、对抗/故障注入
- 指标: failure recovery、unsafe action propagation、latency、cost

8. 关键人物、团队与代表工作

下表按研究传统整理代表性团队和作者。它不试图穷尽所有作者，而是标出每条分支最常被引用的节点。

研究传统	代表作者/团队	代表工作	时间
CTDE 与混合合作-竞争	Ryan Lowe、Igor Mordatch 等	MADDPG	2017
价值分解	Sunehag、Rashid、Whiteson 等	VDN、QMIX	2017-2018
反事实信用分配	Jakob Foerster、Shimon Whiteson 等	COMA	2018
合作 MARL 基线	Chao Yu、Yi Wu 等	MAPPO	2021
角色分化	Tonghan Wang 等	ROMA	2020
学习信号设计	Jiachen Yang 等	LIIR	2020
推理与行动循环	Shunyu Yao 等	ReAct、Tree of Thoughts	2022-2023
语言反思	Noah Shinn 等	Reflexion	2023
生成式社会模拟	Joon Sung Park、Michael Bernstein、Percy Liang 等	Generative Agents	2023
角色对话架构	Guohao Li 等	CAMEL	2023
可编程多智能体框架	Qingyun Wu 等	AutoGen	2023
SOP 与软件工程	Sirui Hong 等	MetaGPT	2023
多角色软件开发	Chen Qian 等	ChatDev	2023
多智能体辩论	Yilun Du 等	Multiagent Debate	2023
图优化编排	Mingchen Zhuge 等	GPTSwarm	2024
LLM 奖励设计	Yecheng Jason Ma、Linxi Fan 等	Eureka	2023
语言到奖励	Tianbao Xie 等	Text2Reward	2023
多机器人语言协作	Zhao Mandi 等	RoCo	2023
主动协作智能体	Ceyao Zhang 等	ProAgent	2024
伙伴建模	Logan Cross 等	Hypothetical Minds	2024
多智能体 LLM 的 RL	Chanwoo Park、Kaiqing Zhang、Asuman Ozdaglar 等	MAPoRL	2025
多轮信用分配	Lang Feng 等	GiGPO	2025

研究传统	代表作者/团队	代表工作	时间
多智能体 RL 训练	Zihan Wang 等	RAGEN	2025
长程多轮训练	Zhiheng Xi 等	AgentGym-RL	2025
LLM critic 与信用解释	Kartik Nagpal、Negar Mehr 等	LLM-MCA	2025
双层奖励设计	Pengyi Li、Hongyao Tang、Yifu Yuan、Jianye Hao 等	ReMAC	2025
分层 LLM + MARL	Minghong Geng 等	L2M2	2025
LLM 辅助 MARL 样本效率	Guobin Zhu、Shiyu Zhao 等	LAMARL	2025
多智能体失败分类	Cemri 等	MAST	2025
集合策略优化	Shengtian Yang 等	SRPO	2026
回合级信用	Chusen Li 等	TRACER	2026
技能持续优化	Huaiyuan Yao 等	MASkills	2026
训练动态稳定性	Regime-Conditional 作者团队	LLM-augmented MARL stability	2026

完整作者、DOI、arXiv、年份和本地 PDF 路径见：

- data/milestones.csv
- data/curated_bibliography.csv
- data/references.bib

9. 研究机会与可执行路线

9.1 机会一：验证 credit 的因果正确性

问题：LLM-MCA、GiGPO、TRACER、MASkills 都在生成细粒度信用，但多数工作只用最终任务分数验证。

可执行实验：

- 在可枚举环境中计算 leave-one-out contribution；
- 用 Shapley 近似或反事实 rollout 作为参考；
- 测量 LLM credit 与真实贡献的 rank correlation；
- 加入随机 credit 和错误 credit 对照组；
- 测试 credit 错误但最终分数仍高的 reward hacking 场景。

成功标准：不仅任务分数提高，而且 credit 与反事实贡献显著相关。

9.2 机会二：研究奖励平稳性与 replay 污染

问题：LLM 奖励通常随训练反馈迭代，但 off-policy MARL 的 replay buffer 假设奖励标签稳定。

可执行实验：

- 比较固定奖励、周期性更新奖励、每步更新奖励；
- 记录 replay buffer 中不同奖励版本的样本比例；
- 测量 PBRs 条件是否满足；
- 比较 reward scaling、normalization 和重标注策略；
- 在 SMAC、ManiCraft、LBF 上验证。

成功标准：给出奖励更新频率与训练稳定性的可复现关系，并找到可操作的稳定化规则。

9.3 机会三：动态拓扑与通信成本

问题：GPTSwarm、DyLAN、MACNET、Optima、Evolving Orchestration 都在学习拓扑，但评测常只看任务分数。

可执行实验：

- 固定同一模型、样本和总 token 预算；
- 比较固定链、静态 DAG、动态 DAG、随机拓扑；
- 记录通信边数、token 数、延迟和失败恢复率；
- 在工具使用和长程任务上测试拓扑迁移。

成功标准：动态拓扑在同等预算下同时改善任务成功率和通信效率。

9.4 机会四：三 agent、部分观测与异构模型

问题：许多代表工作只覆盖两个 agent，或使用全局观测和同一模型。

可执行实验：

- 从 2 agent 扩展到 3-5 agent；
- 引入局部观测和通信预算；
- 混合不同规模/不同家族的 LLM；
- 测量 agent 移除、角色替换和通信中断的鲁棒性。

成功标准：协作收益随 agent 数和异构性增加仍保持，而不是依赖单 agent 能力绕过协作。

9.5 机会五：统一预算感知评测

问题：不同论文使用不同模型、不同调用频率和不同硬件，结果难以横向比较。

建议建立统一记录表：

预算维度	记录内容
Policy learning	environment steps、gradient steps、rollout tokens
LLM signal	input/output tokens、calls、wall-clock
Search/evolution	reward candidates、reflection rounds、discarded candidates
Deployment	inference latency、memory、external model requirement
Reliability	seed variance、failure recovery、safety violations

成功标准：每篇工作都能报告 performance-per-token、performance-per-GPU-hour 和 performance-per-agent。

9.6 一个 12 周研究路线

周次	目标	交付物
1-2	复现可枚举环境与基线	Matrix Game / Spaceworld / LBF 可运行
3-4	比较人工 reward、LLM reward、LLM credit	信号正确性表
5-6	加入反事实验证和随机对照组	credit correlation 与 hacking rate
7-8	迁移到 SMAC / ManiCraft	return、sample efficiency、消融
9-10	动态拓扑与预算实验	token、latency、通信边数
11-12	可靠性与安全测试	failure recovery、unsafe propagation
13	写作与复现包	论文草稿、代码、数据、图表

10. 结论

回到三个研究问题：

RQ1：两条主线如何形成、分化和相互影响？

LaMAS 从角色对话和软件工程起步，逐步扩展到辩论、反思、社会模拟、动态拓扑和评测；LLM-assisted MARL 从高层规划和奖励设计起步，逐步进入信用分配和策略协同。2025-2026 年，两条线在“多智能体 LLM 的强化学习”处汇聚。

RQ2：哪些团队、时间节点和代表工作推动了领域发展？

2017-2021 年的根节点是 MADDPG、VDN、QMIX、COMA、MAPPO、SMAC、Transformer、GPT-3 和 InstructGPT。2022-2023 年的爆发节点是 ReAct、Reflexion、Generative Agents、CAMEL、AutoGen、MetaGPT、Multiagent Debate、Eureka、Text2Reward 和 RoCo。2024 年进入体系化，2025-2026 年在 MAPoRL、GiGPO、MARFT、SRPO、TRACER、ReMAC 和 LLM-MCA 处汇聚。

RQ3：最新方向和实验方法是什么？

最新方向集中在五处：参数级多智能体 RL、agent/turn/skill 级信用、动态拓扑、预算与可靠性、安全传播。实验方法正在从“最终任务分数”扩展为“任务收益 + 信号正确性 + 成本 + 稳定性 + 安全”的联合评价。

本领域下一阶段最值得推进的问题不是“再加一个 LLM agent”，而是：

如何让 LLM 生成的规划、奖励、信用和协作结构，在多智能体训练中被反事实验证、被预算约束、被跨环境复现。

谁先把这个问题做成标准化评测，谁就会定义下一阶段 MARL + LLM 的研究基线。

附录 A：本地文件结构

MARL_LLM_survey/	
├ papers/	# 150 篇 PDF 全文
├ text/	# 逐页文本抽取
├ data/	
│ └ corpus.json	# 完整语料元数据
│ └ corpus.csv	# 表格版元数据
│ └ curated_corpus.json	# 130 条核心文献
│ └ curated_bibliography.csv	# 核心文献表
│ └ milestones.csv	# 75 个关键节点
│ └ references.bib	# BibTeX
│ └ timeline.csv	# 年份-分支-论文
│ └ download_report.md	# 下载与校验报告
├ figures/	
│ └ 01_timeline.png	
│ └ 02_research_tree.png	
│ └ 03_two_paradigms.png	
│ └ 04_method_matrix.png	
│ └ 05_experiment_protocol.png	
│ └ 06_evidence_coverage.png	
├ scripts/	
│ └ collect_literature.py	# 检索、去重、下载、抽取
│ └ resolve_missing.py	# 定向补全开放全文
│ └ build_survey_assets.py	# 研究树、时间线和图表
│ └ browser_probe.py	# 校园网/出版社页面探测
└ MARL_LLM_综述报告.md	# 本报告

附录 B：关键节点节选

完整 75 个节点见 data/milestones.csv。这里列出发展树的核心骨架：

年份	节点	代表工作	一句话贡献
2017	MARL 根	MADDPG、VDN	CTDE 与价值分解
2018	MARL 根	QMIX、COMA	可扩展价值分解与反事实信用
2019	MARL 评测	SMAC	标准化合作 MARL 环境
2020	LLM 根	GPT-3	少样本上下文学习
2021	MARL 基线	MAPPO	强而稳定的合作 MARL 基线
2022	LLM 根	InstructGPT、CoT、ReAct	指令、推理与行动循环
2022	LLM 规划	SayCan、Inner Monologue	语言计划锚定到可执行技能
2023	LaMAS	CAMEL、AutoGen、MetaGPT	角色、对话与 SOP 编排
2023	LaMAS	Generative Agents、Reflexion、Debate	社会模拟、反思与辩论
2023	LLM 辅助 MARL	Eureka、Text2Reward、RoCo	奖励生成与多机器人语言协作
2024	体系化	GPTSwarm、DyLAN、MACNET、Optima	拓扑与工作流优化
2024	评测化	AgentBench、OSWorld、 τ -bench	工具、Web 与真实计算机评测
2025	汇聚	LLM-MCA、ReMAC、L2M2	credit、双层 reward、分层控制
2025	汇聚	MAPoRL、GiGPO、RAGEN	多智能体 LLM 的 RL
2025	失败分析	MAST	多智能体失败分类
2026	最新前沿	MARFT、SRPO、TRACER、MASkills	参数级、集合级、回合级和技能级优化
2026	稳定性与安全	Regime-Conditional、Unsafe Actions	奖励平稳性与安全传播

附录 C：如何使用这份材料

- **想快速理解领域：**先看 figures/02_research_tree.png，再看第 2-3 节。
- **想做文献汇报：**使用 figures/01_timeline.png、figures/03_two_paradigms.png 和第 4-6 节。
- **想设计实验：**直接看第 7 节和 figures/05_experiment_protocol.png。
- **想继续写论文：**从 data/references.bib 和 data/curated_bibliography.csv 取参考文献，从 data/milestones.csv 取发展脉络。
- **想扩展语料：**运行 python scripts/collect_literature.py，再运行 python scripts/resolve_missing.py 和 python scripts/build_survey_assets.py。

附录 D：边界与后续补全

- 当前本地全文覆盖 150 篇，其中核心文献 114 篇有全文；其余条目保留元数据，不进入实验结论。
- 另外补录了原版 GPT-3 论文 (Brown et al., 2020, arXiv:2005.14165) 作为人工校正版本，文件为 papers/2020_language_models_are_few_shot_learners_original.pdf。
- 2026 年部分工作仍为预印本或审稿稿，结论应视为前沿信号，而不是稳定共识。
- 出版社页面对自动化访问会返回 403/Access Denied；校园网可继续用于人工补齐少量付费墙论文。
- Agent-R1 在 arXiv 和 OpenAlex 中未找到可核实记录，因此未进入正式研究树。
- 建议下一轮重点补全：三 agent/部分观测实验、统一预算评测、credit 反事实验证、奖励平稳性和安全传播。